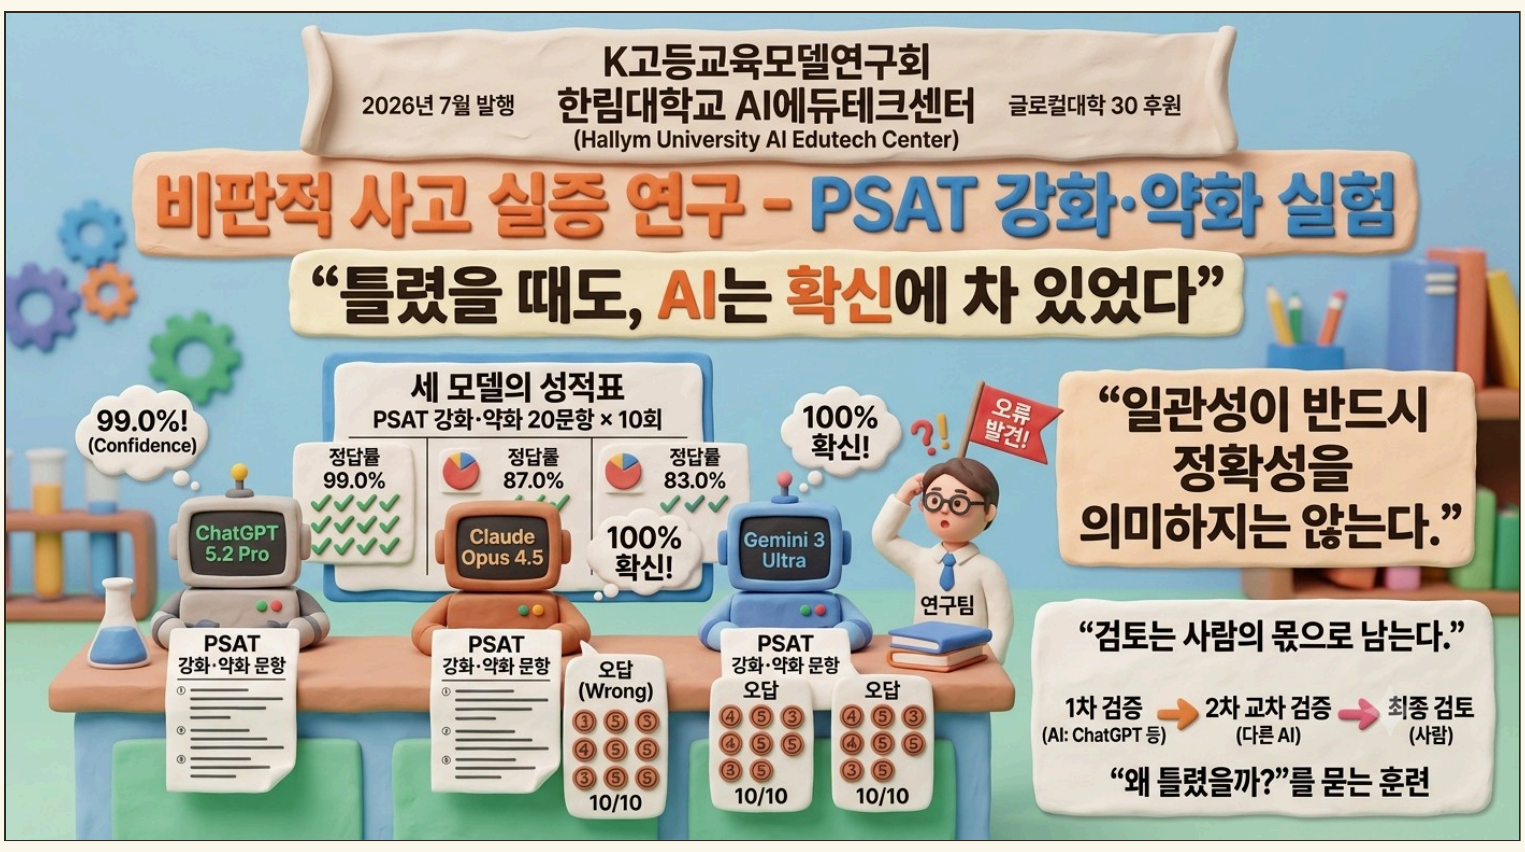
2026.7 · K고등교육모델연구회 실증노트

틀렸을 때도, AI는 확신에 차 있었다

PSAT 강화·약화 문항 20개를 세 모델에게 열 번씩 물었다. ChatGPT는 99%를 맞혔고, Claude와 Gemini는 특정 문항에서 열 번 내내 같은 오답을 골랐다. 연구팀이 확인한 건 정답률이 아니라, 그 정답률이 무엇을 가리키는지였다.

글 K고등교육모델연구회 | 2026-07-06



▲ *PSAT 강화·약화 20문항을 세 모델에게 10회씩 물은 실험 요약. ChatGPT 99.0%, Claude 87.0%, Gemini 83.0%의 정답률 뒤에 숨은 '확신에 찬 오답'을 짚었다.*

결과가 아니라 질문이라고 했다. 컨텐츠 생산력이 극도로 향산된 AI시대에는 올바른 질문을 하는 것이 그 중요성을 더해갈 것이라는 말이다. 생성형 AI가 등장하고 많은 교육자들은 교육에 AI를 도입하기 시작했다. 그런데 과연 교육에 AI를 무작정 쓰는 것이 올바른 것인가? 우리는 질문에 그치지 않고 한번 실험해보기로 했다. 비판적으로 생각한다는 것은 결국 좋은 논증과 나쁜 논증을 가려내는 일이다. 그렇다면 AI는 그 일을 얼마나 잘 해낼까. K고등교육모델연구회의 실험 분과는 이 물음 하나를 붙들고 공직적성평가(PSAT) 문제지를 펼쳤다.

질문을 실험으로 좋은 논증을 알아보는 눈

철학자 스크라이븐은 비판적 사고를 '관찰과 정보, 그리고 논증에 대한 숙련되고 능동적인 해석과 평가'라고 정의했다. 듀이와 글레이저, 에니스와 폴이 저마다 조금씩 다르게 정의를 내렸지만, 겹쳐 놓고 보면 결국 남는 건 하나다. 논증을 읽어내는 능력. 좋은 논증에는 전제가 있고, 그 전제가 결론을 얼마나 단단히 떠받치는지가 있다. 이 지지력을 흔드는 정보가 나타나면 논증은 약해지고, 지지력을 보태는 정보가 나타나면 논증은 강해진다.

가령 어떤 글이 "조건 X가 갖춰질 때마다 현상 Y가 뒤따랐고, 둘의 상관관계도 높다. 따라서 X가 Y의 원인이다"라고 주장한다고 해보자. 여기에 "다른 외부 요인을 모두 통제한 실험에서도 X가 Y를 일으켰다"는 정보가 더해지면 논증은 단단해진다. 반대로 "제3의 변수 Z가 X와 Y를 동시에 일으켰을 뿐"이라는 사실이 드러나면 논증은 무너진다. 이렇게 지문 속 논증의 빈틈을 메우거나 허무는 문제가 PSAT 언어논리와 법학적성시험(LEET) 추리논증의 '강화·약화' 유형이다. 서술형과 달리 다섯 개 선택지 중 하나만 고르면 되니, 채점자의 주관이 끼어들 틈이 없다는 것도 이 유형의 장점이다.

실험 결과 확신에 찬 오답

연구팀은 2019년부터 2025년까지 PSAT 기출에서 강화·약화 문항 20개를 골랐다. 그리고 사람들이 가장 많이 쓰는 세 모델 — ChatGPT 5.2 Pro, Claude Opus 4.5, Gemini 3 Ultra — 에게 같은 20문항을 열 번씩 반복해서 풀게 했다. 매 회차 전에는 시크릿 모드로 접속 기록을 지웠고, "검색하지 말고 스스로 추론해서 답하라"는 조건을 못박았다. 한 번만 풀게 하고 끝내지 않은 이유는 간단하다. AI의 답은 매번 똑같지 않다. 그 흔들림 자체가 중요한 데이터이기 때문이다.

종합 정답률은 ChatGPT가 99.0%로 가장 높았고, Claude 87.0%, Gemini 83.0%가 뒤를 이었다. 여기까지는 예상 가능한 순위표처럼 보인다. 흥미로운 지점은 그다음이다. Claude는 한 문항에서 열 번 모두 같은 오답을 골랐다. 정답이 ④인 문항에서 열 번 내내 ⑤를 찍은 것이다. Gemini도 다르지 않았다. 서로 다른 두 문항에서 각각 열 번 연속으로 같은 오답을 반복했다. 우연히 틀린 게 아니라, 매번 똑같이 확신을 갖고 틀린 셈이다.

> 모델은 확신을 가지고, 반복적으로 틀릴 수 있다.
>
> — 실험 분과 관찰 기록

이 결과가 말해주는 건 하나다. 일관성이 곧 정확성은 아니라는 것. ChatGPT의 일관성은 높은 정답률과 겹쳐 신뢰를 더했지만, Gemini의 일관성은 오히려 하나의 오답을 단단히 붙들고 있었을 뿐이다. 통계적으로도 모델 간 정답률 차이는 우연이 아니었다($p<.001$). 그럴듯하게 말하는 것과 옳게 말하는 것은, 적어도 이 실험에서는 서로 다른 이야기였다.

"일관성이 반드시 정확성을 의미하지는 않는다."

세 모델의 성적표 — PSAT 강화·약화 20문항 × 10회

ChatGPT 5.2 Pro
정답률 99.0% — 10회 중 8회 만점. 오답은 두 문항에서 산발적으로만 나타났다.

Claude Opus 4.5
정답률 87.0% — 만점 회차는 한 번도 없었다. 한 문항은 열 번 모두 같은 오답이었다.

Gemini 3 Ultra
정답률 83.0% — 서로 다른 두 문항에서 각각 열 번 연속 같은 오답을 반복했다.

그래서, 어떻게 쓸 것인가 검토는 사람의 몫으로 남는다

연구팀은 여기서 멈추지 않고 제안 하나를 내놓았다. 정확도가 가장 높은 모델을 1차 검증 도구로 세우고, 나머지 모델로 2차 교차 검증을 거치자는 것이다. 세 모델이 모두 동의한 문항은 믿을 만한 문항으로 분류하고, 의견이 갈린 문항은 반드시 사람이 다시 들여다본다. 실제로 20문항 중 13문항은 세 모델 모두 만점이었지만, 나머지 7문항에서는 모델마다 약점이 뚜렷하게 갈렸다.

더 눈에 띄는 제안은 따로 있다. 세 모델의 답이 갈린 문항을 학생에게 그대로 보여주고, "왜 이 모델은 여기서 틀렸을까"를 캐묻게 하자는 것이다. AI의 오답을 뒤쫓는 과정 자체가 논증을 뜯어보는 훈련이 된다는 발상이다. 이는 앞서 K고등교육모델연구회가 던졌던 물음 — AI에게 물어보면 되는데, 왜 우리는 공부라는 어려움을 스스로 감당해야 하는가 — 에 대한 하나의 응답이기도 하다. 정답을 빨리 얻는 것과, 그 정답이 왜 정답인지 스스로 따져보는 것은 다른 능력이라는 사실을, 이 실험은 숫자로 보여준 셈이다.

연구팀은 이 실험을 「AI의 논증 평가 능력 검증 — PSAT 강화·약화 문항 중심으로」라는 제목으로 논문을 작성 후 투고할 예정이다. 아직 5개월 가량의 연구 기간이 남았지만 K고등교육모델연구회의 추진력은 시작부터 남달랐다. 여러 가지 올바른 질문과 실험 계획을 구상하고 그에 맞는 올바른 결론을 도출해야 한다. 성급히 결론을 내기엔 아직 이르다. 하지만 한 가지는 분명해졌다. 잘 대답하는 AI와, 그 대답이 왜 옳은지 아는 사람 사이의 거리는 가까워 보이지만 여전히 큰 간극이 존재한다.