K고등교육모델연구회

한림대학교 AI에듀테크센터 · 글로컬대학 30 후원

2026년 8월 24일 발행

7월 세미나 지상중계 · 유미나 교수 초청 강연

K고등교육모델연구회 | 한림대학교 AI에듀테크센터 | 글로컬대학 30 후원

2026. 7. 20 · ZOOM 초청 세미나

인공지능 시대의 서술형 평가, AI 에이전트에게 채점을 맡겨보았다

춘천교육대학교 교육학과 유미나 교수 초청 강연 — "학생은 AI로 과제를 쓰고 교수는 AI로 채점하는 시대, 우리는 무엇을 어떻게 평가해야 하는가." 직접 개발한 서술형 평가 AI 에이전트의 시도와 성과, 그리고 한계까지 숨김없이 공유한 두 시간을 정리했다.

글 **K고등교육모델연구회** | 발행 2026-08-24 | 강연 2026-07-20 14:00, ZOOM

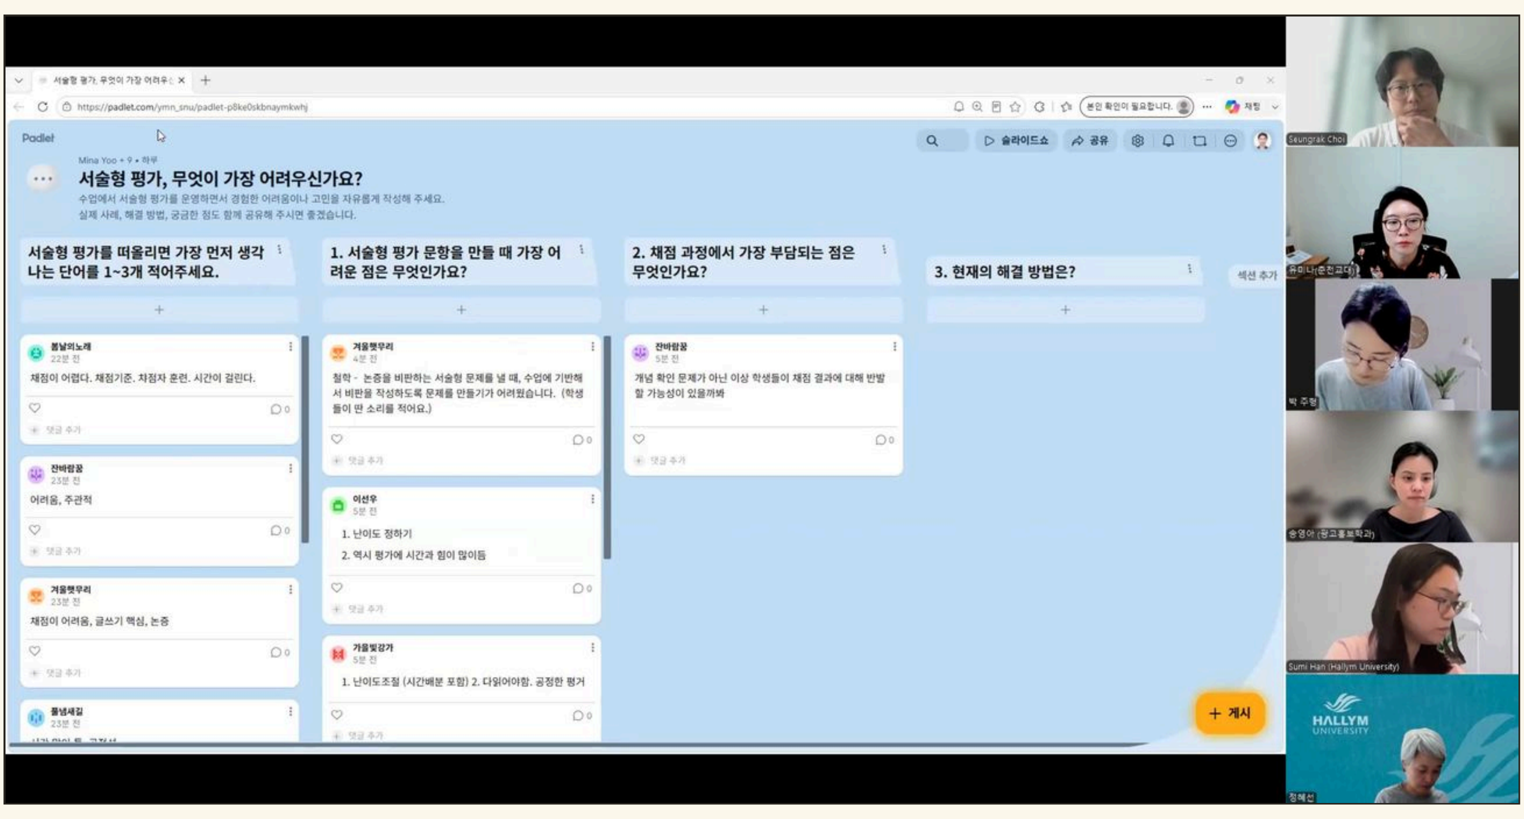
Padlet
Mina Yoo • 9 • 하루
서술형 평가, 무엇이 가장 어려우신가요?
수업에서 서술형 평가를 운영하면서 경험한 어려움이나 고민을 자유롭게 작성해 주세요.
실제 사례, 해결 방법, 궁금한 점도 함께 공유해 주시면 좋겠습니다.
서술형 평가를 떠올리면 가장 먼저 생각나는 단어를 1~3개 적어주세요.
1. 서술형 평가 문항을 만들 때 가장 어려운 점은 무엇인가요?
2. 채점 과정에서 가장 부담되는 점은 무엇인가요?
3. 현재의 해결 방법은?
채점이 어렵다. 채점기준. 채점자 훈련. 시간이 걸린다.
어려움, 주관적
채점이 어려움, 글쓰기 핵심, 논증
철학 - 논증을 비판하는 서술형 문제를 낼 때, 수업에 기반해서 비판을 작성하도록 문제를 만들기가 어려웠습니다. (학생들이 딴 소리를 적어요.)
1. 난이도 정하기
2. 역시 평가에 시간과 힘이 많이듦
1. 난이도조절 (시간배분 포함) 2. 다읽어야함. 공정한 평가
개념 확인 문제가 아닌 이상 학생들이 채점 결과에 대해 반발할 가능성이 있을까봐
+ 게시
Seungrak Choi
유미나(춘천교대)
박주형
Sumi Han (Hallym University)
HALLYM UNIVERSITY
정혜선

▲ *7월 20일 ZOOM 세미나. 유미나 교수(춘천교대)가 패들렛으로 "서술형 평가, 무엇이 가장 어려우신가요?"를 물으며 강연을 열었다. 참여 교수들은 "채점이 어렵다", "주관적", "난이도 설정", "공정성"을 첫 단어로 꼽았다.*

"학생이 AI로 작성한 과제를, 우리가 다시 AI로 채점하는 시대가 된 것 같습니다." 지난 7월 20일, K고등교육모델연구회가 초청한 유미나 교수(춘천교육대학교 교육학과·교육공학)는 이 한 문장으로 강연의 문을 열었다. 학습 분석(러닝 애널리틱스)을 십년 넘게 연구해 온 유 교수는 '인공지능 시대의 서술형 평가: AI 에이전트 개발 사례'라는 제목으로, 직접 만들어 본 서술형 평가 자동 채점 에이전트의 개발 과정을 공개했다.

강연은 일방적인 발표가 아니었다. 유 교수는 패들렛(Padlet)에 네 개의 질문판을 띄우고 참여 교수들의 답을 실시간으로 모았다. 서술형 평가 하면 떠오르는 단어로는 "어려움", "주관적", "채점이 어려움", "공정성"이 쏟아졌고, 출제의 어려움으로는 난이도 설정과 답안 범위 지정이, 채점의 어려움으로는 일관성과 학생 이의 제기에 대한 부담이 꼽혔다. 진단은 공통적이었다. 서술형 평가는 교육적 가치가 크지만, 그 가치만큼 품이 든다는 것이다.

강연 1 무엇을 평가할 것인가 — 서술형 평가의 여섯 유형

유 교수는 먼저 이론적 토대를 정리했다. 서술형 평가는 정답을 고르는 평가가 아니라 학습자가 답을 구성하는 과정과 결과를 함께 보는 평가다. 유형은 여섯 가지로 나뉜다. 핵심 개념을 자기 언어로 설명하는 **개념 설명형**, 두 이론을 기준에 따라 견주는 **비교 분석형**, 주장·근거·반론·재반론을 구성하는 **논증형**, 복합 상황의 해결 방안을 제시하는 **문제 해결형**, 경험을 이론에 근거해 돌아보는 **성찰형**, 자료 수집과 분석으로 결론을 도출하는 **연구형**이다. 중요한 것은 모든 유형을 다 쓰는 것이 아니라, 측정하려는 학습 목표에 맞는 유형을 고르는 일이라고 유 교수는 강조했다.

공정성 문제에 대한 유 교수의 처방은 '평가 루브릭'이었다. 성찰일지 과제라면 구성·내용·완성도의 세 항목을 상·중·하 기준으로 미리 명문화해 공개하고, 그 기준대로만 채점하는 것이다. "수업 태도가 좋은 학생의 과제에 점수를 잘 주고 싶어지는 후광 효과를 지우고 싶었다"는 고백은 많은 교수들의 공감을 샀다.

강연 2 무엇을 만들었나 — 5단계 협업형 채점 에이전트

> "AI가 아무렇게나 '이 학생은 93점, 이유는 논리적이어서'라고만 하면 그 시스템을 믿을 수 없다고 했다. 근거 문장을 짚어줄 수 있어야 했다."
>
> — 유미나 교수

본론은 유 교수가 인공지능 전공 연구소 소장과 함께 개발한 AI 에이전트였다. 연구비 지원 없이 "채점이 너무 힘들다"는 개인적 필요에서 출발한 시스템이다. 생성형 AI가 추천까지 해준다면, 에이전틱 AI는 판단과 실행까지 대신한다. 이 에이전트는 교수자가 과제와 루브릭을 등록하면 학생 답안 파일(HWPX·DOCX)을 읽고 루브릭 항목별로 점수 초안을 산출하는데, 핵심은 점수마다 답안 속 **근거 문장**을 짚어 "경험에서 시작해 논리적으로 전개했다"는 식의 판단 이유를 붙여 준다는 점이다. 채점 모델은 클로드와 제미나이 중 선택할 수 있고, 정밀·표준·빠름의 속도 옵션도 있다.

워크플로우는 5단계로 설계됐다. ① 교수자가 과제·루브릭 설계 → ② AI가 항목별 점수 초안과 근거 제시 → ③ AI가 피드백 초안 생성 → ④ 교수자가 수정한 피드백을 AI가 한 번 더 다듬기 → ⑤ 교수자가 최종 확정 후 학생에게 전송. 특히 4단계는 개발자의 제안이었다. 교수의 문장과 AI의 문장이 섞이면 어조가 어긋나 학생이 어색함을 느끼기에, AI가 전체를 한 번 더 윤문하는 단계를 끼워 넣은 것이다. "AI가 도와주지만 최종 결정권은 반드시 교수자가 갖는다"는 원칙이 설계 전체를 관통한다.

효과는 분명했다. 한 페이지 분량 답안 하나를 채점하는 데 1분이 채 걸리지 않았고, 유 교수는 "채점 시간이 50분의 1로 줄어드는 셈"이라고 했다. 이름을 지우고 넣었더니 "왜 이 항목에서 감점됐는지를 정말 정확하게 짚어 주더라"며 결과에도 만족했다. 개별 피드백을 한 번도 주지 못했던 성찰일지 과제에, 근거 있는 맞춤형 피드백을 줄 수 있게 된 것이 가장 큰 소득이었다.

한계 그러나 문제도 숨기지 않았다

유 교수는 한계도 그대로 공개했다. 연구비가 없어 토큰 비용 때문에 답안 10개로만 검증했고, 학회 발표 뒤 서버는 닫혀 있어 이날도 캡처 화면으로 시연을 대신했다. 학생용 화면은 만들지 못했고, 채점 결과를 보고 루브릭 자체를 고쳐 주는 기능도 아직 없다. 손글씨 답안은 OCR로 텍스트화하는 별도 기술이 필요하고, GPT 킬러 같은 도구로 AI 작성 여부를 가려내는 것은 "제 글로 실험해 보니 전혀 정확하지 않았다"고 했다. 결국 AI 사용을 막고 싶다면 규정이 아니라 AI로 할 수 없는 과제 설계로 풀어야 한다는 것이다.

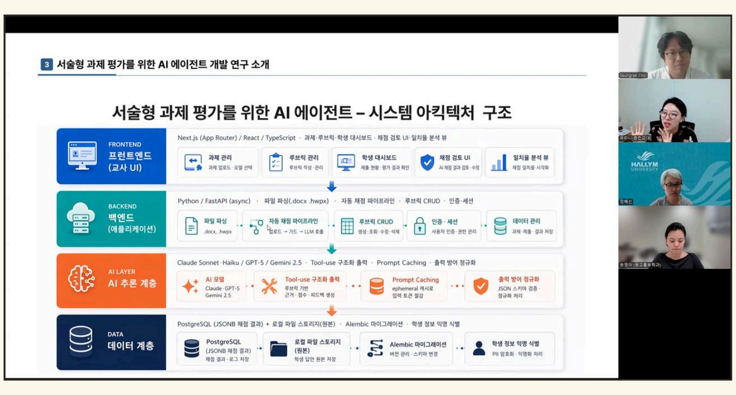

▲ *시스템 구조. Next.js 기반 교수자 화면, FastAPI 백엔드, 클로드·GPT-5·제미나이를 쓰는 AI 추론 계층, 학생 정보를 익명화하는 데이터 계층으로 구성됐다.*

질의응답 "시간이 정말 절약되는가" — 두 시간을 채운 토론

질의응답은 강연만큼 길고 구체적이었다. 이선우 교수(소프트웨어학부)가 실사용 만족도와 시간 절감을 묻자 위의 "50분의 1" 답이 나왔다. 정혜선 교수(심리학과)는 곧장 반론을 보탰다. "AI로 작업하면 오히려 시간이 더 드는 경험을 한다. AI 초안을 읽고 검토하고 보태다 보면, 절약되는 것은 전달 시간이지 전체 시간이 아닐 수 있다"는 것이다. 두 사람은 "시간이 크게 줄지 않더라도, 이제까지 못 해왔던 개별 피드백이 가능해지니 평가의 질은 올라간다"는 데서 합의점을 찾았다.

정 교수는 두 가지를 더 물었다. 학생 답안을 외부 AI에 올려도 되는가에 대해 유 교수는 "답안이 학습에 쓰이지 않도록 서버 안에서만 돌아가게 보안을 설정했다. 개방형 챗GPT보다는 폐쇄형 에이전트를 쓰라"고 답했다. 학생 답안의 분포를 보고 루브릭을 사후 수정하고 싶다는 요청에는 "내 에이전트에는 아직 없지만, 지금의 에이전트 기술로는 충분히 가능하다"며 다음 연구 과제로 받아들였다.

최영재 교수(미디어스쿨)는 현실을 짚었다. "서술형 과제를 내면 80~90%는 AI가 쓴다고 봐야 한다. 25명 중 22명이 인터뷰 과제를 AI로 만들어 왔다"는 경험담과 함께, 수강생이 60명으로 늘어나는 다음 학기 글쓰기 수업의 고민을 털어놓았다. 그는 유료 AI를 쓰는 학생과 무료 AI를 쓰는 학생 사이에 평가 격차가 생기는 'AI 디바이드'라는 더 큰 윤리 문제도 제기했고, "채점을 자동화하기보다 아예 발상을 바꿔 AI의 도움으로 글쓰기를 잘하게 하는 교육과정을 만들자"는 제안으로 토론을 넓혔다.

현장의 대안도 나왔다. 이정근 교수(소프트웨어학부)는 수기 답안지를 PDF로 스캔해 자동 채점하는 시스템을 직접 개발해 쓰고 있다고 소개했다. 문제당 비용은 1센트가 되지 않고, 답안 80장을 한 번에 올리면 채점이 끝난다. 그는 "AI 채점은 100% 정답이 아니라 '가채점'으로 받아들여야 한다"며, 교수자가 수정한 내역을 데이터로 쌓으면 어떤 모델이 교수자와 가장 가깝게 채점하는지 통계로 검증할 수 있다는 아이디어를 보탰다. 에듀테크센터가 향후 스마트리드에 이 시스템을 반영하겠다는 계획도 확인됐다. 박주형 교수(경영학과)는 이미 한 학기를 운영한 경험을 공유했다. 학기 첫 시간에 "너희도 AI를 써도 되고, 나도 AI로 평가한다"는 것을 루브릭과 함께 투명하게 공개하고 동의를 받았으며, 보고서와 함께 코드·데이터를 제출하게 해 실제 수행 여부를 검증하고, AI가 문제를 표시한 답안만 교수가 재검증하는 방식이다. "과정을 투명하게 열어야 학생도 윤리적으로 응답한다"는 결론이었다.

마지막 쟁점은 루브릭 공개의 역설이었다. 한 참석 교수는 "루브릭을 다 알려주면 학생들이 AI에게 루브릭을 주고 맞춤 작성을 시킬 텐데, 변별력은 시간 문제 아니냐"고 물었다. 정혜선 교수는 "큰 가이드라인(아웃라인)만 미리 공개하고 세부 루브릭은 사후에 공개하되, 같은 루브릭을 계속 쓰면 결국 족보처럼 퍼지므로 주기적으로 바꿔야 한다"는 절충안을 제시했다. 모델마다 채점 결과가 달라지는 문제까지 더해, 종단 연구가 필요하다는 데 의견이 모였다.

향후 과제 세미나가 남긴 숙제

이날 논의는 앞으로 할 일의 목록이기도 하다. 학생 답안 분포를 반영해 루브릭을 자동 개선하는 기능, 루브릭 항목과 답안 속 근거 문장을 하이라이트로 연결해 보여주는 화면, 교수자 수정 데이터를 축적한 모델별 일치율 검증, 수기 답안 OCR의 정확도 확보, 그리고 AI 활용 범위를 강의계획서에 사전 고지하는 윤리 절차의 정착이다. 나아가 최영재 교수의 제안처럼, AI 시대의 평가는 '치팅을 막는 채점'을 넘어 'AI와 함께 더 잘 쓰고 더 잘 배우게 하는 교육과정 설계'로 나아가야 한다는 큰 방향도 확인됐다. 유 교수는 "지난주와 이번 주가 다른 속도의 시대"라며 "다음 학기에 무엇부터 시작할지 각자 정해 보시라"는 질문을 남기고 강연을 맺었다.